Métricas DORA em Repositórios Populares do GitHub: Desempenho e Sensibilidade às Definições Operacionais

Vitor Costa Vianna[1], **Joaquim Vilela**[1], **Gabriel Nogueira Vieira Resende**[1]

[1]Engenharia de Software – Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Laboratório de Experimentação de Software – Noite / 6º período – Prof. Danilo Maia
Lab03 – Mineração de Métricas DORA – Entrega: 22/10/2026
`https://github.com/lab-medicao-experimentacao/lab03-mineracao-metricas-DORA`
GitHub Projects: `https://github.com/orgs/lab-medicao-experimentacao/projects/3`

Abstract. *DORA metrics are the industry standard for software delivery performance, but open-source projects record neither production deploys nor production failures. We mined 300 popular GitHub repositories that use GitHub Actions over a 12-month window and approximated the four metrics with releases, commits and CI runs. The median repository publishes 0.35 releases per week, has a lead time of about 7.8 days, a CI failure rate of 6% and recovers from a failing workflow in 4.2 hours; most repositories are High or Medium. The classification, however, depends heavily on the operational definition: replacing the CI-based failure rate with a delivery-based proxy changes the overall category of up to 41.7% of the repositories (weighted* $\kappa = 0.42$*).*

Resumo. *As métricas DORA são o padrão de mercado para medir o desempenho de entrega de software, mas projetos open-source não registram deploys nem falhas em produção. Mineramos 300 repositórios populares do GitHub que usam GitHub Actions, numa janela de 12 meses, e aproximamos as quatro métricas por releases, commits e execuções de CI. O repositório mediano publica 0,35 release por semana, tem lead time de cerca de 7,8 dias, taxa de falha de CI de 6% e se recupera de um workflow com falha em 4,2 horas; a maioria fica nas faixas High e Medium. A classificação, porém, depende muito da definição operacional: trocar o CFR de CI por um proxy de entrega muda a categoria geral de até 41,7% dos repositórios (*κ *ponderado = 0,42).*

1. Introdução

As métricas DORA (*DevOps Research and Assessment*) – frequência de deploy, *lead time for changes*, *change failure rate* (CFR) e tempo de recuperação – são a referência para medir a entrega de software [Forsgren et al. 2018, DORA 2024], mas pressupõem deploys e falhas em produção, que projetos open-source não registram. Aproximamos as quatro métricas com releases, commits e execuções de CI para (i) descrever o desempenho DORA de repositórios populares e seus fatores associados e (ii) medir o quanto as conclusões dependem das definições operacionais. As hipóteses das RQ01, RQ02 e RQ05–RQ07 foram registradas no repositório antes da coleta; as das RQ03 e RQ04 só foram registradas depois dela e servem apenas como referência.

RQ01. Qual a frequência de deploys dos repositórios populares que usam CI/CD? *Hipótese:* mediana na faixa Medium, distribuição assimétrica à direita, poucos

Elite (publicação automatizada) e faixa Low reduzida pelo critério de inclusão ($\geq$ 5 releases).

RQ02. Qual o tempo entre um commit e seu deploy? *Hipótese:* o lead time por commit (b) fica abaixo do lead time por release (a) na maioria dos repositórios, porque (a) é dominado pelo commit mais antigo.

RQ03. Qual a taxa de falha das mudanças entregues? *Hipótese:* CFR (a) mediano na faixa Elite ($\leq 15\%$), porque os runs de *push* no *default branch* vêm de mudanças já revisadas em *pull requests*; CFR (b) bem maior que o (a), com as duas variantes classificando os repositórios de forma diferente.

RQ04. Qual o tempo de recuperação após uma execução de CI com falha? *Hipótese:* mediana abaixo de um dia (faixa High), porque uma falha de CI costuma ser resolvida por um novo *push* ou *re-run*, com cauda longa à direita e poucos episódios censurados.

RQ05. Repositórios com maior frequência de deploy têm maior ou menor taxa de falha? *Hipótese:* correlação de Spearman fraca, possivelmente diferente entre as duas variantes de CFR.

RQ06. Quais características estão associadas a melhor desempenho? *Hipótese:* fatores de processo (tipo do projeto, contribuidores) mais associados que popularidade (estrelas), com efeitos pequenos a médios; mais contribuidores implicariam maior frequência e recuperação mais rápida; repositórios antigos teriam menor frequência e menor CFR.

RQ07. O quanto a classificação DORA depende da definição operacional? *Hipótese:* cerca de um terço dos repositórios muda de categoria geral, com κ ponderado moderado (0,4–0,6) e mudanças sobretudo para categorias adjacentes.

Além das RQs do enunciado, propusemos quatro inovações (Seção 3.6): decomposição da RQ07 por métrica, funil de seleção aleatorizado, coleta paralela determinística e verificação cruzada da classificação DORA.

2. Contexto

O Lab03, terceiro laboratório da disciplina, retoma a mineração de repositórios do GitHub do Lab01, inclui uma validação manual e fornece os dados do Lab04. Estudamos repositórios públicos com mais de 1.000 estrelas que usam GitHub Actions. As métricas e as faixas Elite, High, Medium e Low vêm do *Accelerate* [Forsgren et al. 2018] e do DORA [DORA 2024]; a análise (mediana, IQR, testes não paramétricos e tamanhos de efeito [Romano et al. 2006]) e as ameaças à validade seguem Wohlin et al. [Wohlin et al. 2012].

3. Metodologia

3.1. Principais desafios

Limites da API: a busca e o endpoint de runs devolvem até 1.000 itens por consulta; fatiamos a busca por faixas de estrelas e os runs por mês, e registramos os 24 repositórios que ainda tiveram meses saturados (126 meses). **Interrupções:** cada resposta é salva em disco, e o pipeline retoma de onde parou. **Ambiguidade:** lead time, CFR e recuperação admitem várias leituras; fixamos cada regra no código e nos testes. **Rotulagem:** julgar

se uma release é corretiva exige ler *release notes* e commits, e em monorepos a release anterior pode ser de outro pacote.

3.2. Tomadas de decisão

Janela fechada (1/10/2025 a 30/09/2026, UTC), anterior à coleta, para que os dados não mudem entre execuções. **Inclusão:** ≥ 5 releases e ≥ 50 runs válidos no *default branch* na janela. **Funil sob demanda:** candidatos embaralhados (semente 42) antes de qualquer consulta e avaliados nessa ordem até completar 300. **Ausência $\neq$ zero:** sem episódio de falha, a recuperação fica vazia (zero daria Elite sem evidência), e a categoria geral usa as demais, se restarem três. **Censura:** episódios abertos ao fim da janela entram com a duração até o fim, e releases dos últimos 7 dias saem do CFR (b). **WIP:** até 2 Issues "In progress" por integrante, para concluir antes de abrir nova frente; todo PR é revisado por outro integrante.

3.3. Etapas

A Tabela 1 segue os Assignees das Issues; as seções do artigo (#13, #36, #51) foram escritas pelos três. O quadro tem as colunas Backlog $\rightarrow$ Ready $\rightarrow$ In progress $\rightarrow$ In review $\rightarrow$ Done.

Tabela 1. Entregas por sprint (A = Vitor, B = Joaquim, C = Gabriel).

Sprint	Entregas (Issues)	Resp.
S01	Estrutura e CI (#1, #21); busca e funil (#3–#5); classificação (#6)	A
	Releases, tags e commits (#7, #8); lead time (a) e (b) (#11)	B
	Cliente HTTP e cache (#2, #10); runs (#9); CFR (a) e recuperação (#12)	C
S02	Amostra-ouro, rotulagem e kappa de Fleiss (#29, #30, #33)	A
	CFR (b) e heurística (#28); rotulagem (#31); F1 da heurística (#34)	B
	Coleta dos 300 (#27); rotulagem (#32); dataset e dicionário (#35)	C
S03	RQ01–RQ04 e C1 (#48, A); RQ05 e RQ06 (#46, #47, B); RQ07 (#49, C)	A/B/C

O quadro completo, com as Issues, os Assignees e o histórico de cada cartão, está no GitHub Projects do grupo (link no cabeçalho).

3.4. Ferramentas

Cliente HTTP próprio (`requests` 2.32) sobre as APIs REST e GraphQL do GitHub, sem bibliotecas de acesso à API; pandas 2.2, NumPy 2.2, SciPy 1.14, statsmodels 0.14 (Holm, kappa de Fleiss) e scikit-learn 1.5 (kappa de Cohen, F1); Matplotlib 3.9; pytest e pytest-cov (cobertura $\geq 80\%$ do módulo `metricas`, verificada na CI); GitHub Projects (v2). O pipeline roda com `python -m pipeline --config config.yaml`, que fixa janela, faixas, critérios e semente.

3.5. Tabela de métricas

Deploy é uma release publicada (`draft` e `prerelease` falsos), datada por `published_at`; a data de um commit é `commit.author.date`; só contam runs com `event = push` no *default branch*, em que `success` é sucesso, `failure`,

Tabela 2. Métricas, definições operacionais e fonte (endpoint REST ou dataset).

RQ	Definição operacional	Unidade	Fonte
01	Releases da janela ÷ 52,1 semanas	rel./sem.	`releases`
02	`published_at`(R) − (a) commit mais antigo de R, mediana entre releases; (b) cada commit de R, mediana de todos os commits	horas	`compare`
03	(a) runs com falha ÷ (falhas + sucessos); (b) releases seguidas em até 7 dias por uma corretiva ÷ releases avaliadas	fração	`runs`, `compare`
04	Da 1ª falha após um sucesso (`run_started_at`) ao próximo sucesso do workflow (`updated_at`); mediana dos episódios	horas	`runs`
05–07	ρ de Spearman (RQ05); Kruskal-Wallis com Holm e $\varepsilon^2 = H/(n-1)$ (RQ06); % de mudança de categoria e κ de Cohen linear (RQ07)	–	dataset

`timed_out` e `startup_failure` são falha, e os demais valores são ignorados (Tabela 2).

Uma release é **corretiva** (heurística v3) se, descontados merges e commits de manutenção, os títulos dos commits trazem *fix*, *hotfix*, *revert* ou variantes – em maioria estrita, quando há títulos de funcionalidade – ou, sem funcionalidades, se só o *patch* SemVer aumenta no mesmo pacote. Os cortes da disciplina para Elite, High e Medium (abaixo do último, Low) são: frequência ≥ 7, ≥ 1 e $\geq 0{,}23$ por semana (1/mês); lead time < 1 dia, < 1 semana e < 30 dias; CFR $\leq 15\%$, $\leq 30\%$ e $\leq 45\%$; recuperação $<$ 1 hora, < 1 dia e < 1 semana. A categoria geral é a mediana das notas (Elite = 4 … Low = 1), arredondada para baixo. Na RQ07, **C1** (referência) usa release, lead time (a) e CFR (a); **C2**, release + pré-release, lead time (b) e CFR (b); **C3**, tag (datada pelo commit apontado), lead time (b) e CFR (a). A recuperação não muda.

Validação manual. Sorteamos 60 repositórios (semente 42) e 5 releases de cada. Os três integrantes rotularam, às cegas, o tipo do projeto, se as releases são entregas reais e se cada release é corretiva. O kappa de Fleiss foi "quase perfeito" [Landis and Koch 1977] no tipo (85,0%; $\kappa = 0{,}845$) e nas corretivas (88,3%; $\kappa = 0{,}828$); nas entregas reais, todos marcaram "sim". O consenso por maioria deu 103 corretivas em 300. Contra ele, com meta de F1 $\geq 0{,}70$, a heurística teve precisão, *recall* e F1 de 0,375, 0,952 e 0,538 na v1 (qualquer commit com *fix*, *revert* ou *hotfix*, ou só *patch*); 0,667, 0,447 e 0,535 na v2; e 0,682, 0,728 e 0,704 na v3, adotada (110 corretivas previstas).

3.6. Inovações propostas pelo grupo

(a) Decomposição da sensibilidade por métrica (metodologia): comparamos cada métrica, e não só a categoria geral, entre as combinações para achar *o que* move a classificação (RQ07, Seção 4.2). **(b) Funil aleatorizado sob demanda (metodologia):** como o embaralhamento precede as consultas, os 2.338 avaliados são uma amostra aleatória simples dos 60.083 candidatos e estimam as taxas de descarte da população. **(c) Coleta paralela determinística (arquitetura):** *threads* com saída na ordem da amostra e registro dos meses saturados. **(d) Verificação cruzada (controle de ameaça):** duas

implementações independentes da classificação C1 coincidem nos 300 repositórios.

4. Resultados

4.1. Coleta de dados

Dos 2.338 avaliados, 12,8% foram elegíveis (Tabela 3); a maior perda é o critério de releases (só 30,2% dos que usam Actions publicaram ≥ 5). Das 11.088 releases da amostra, o lead time usa as 8.500 com ao menos um commit (71 sem release anterior, 56 com *compare* falho e 2.461 sem commits novos). Extremos foram mantidos (a análise usa mediana e IQR).

Tabela 3. Funil de seleção (da 3ª etapa em diante, só os avaliados).

Etapa	Restantes	Descartados	Motivo
Candidatos da busca	66.219	–	–
Sem fork e não arquivados	60.083	6.136	773 forks; 5.363 arquivados
Avaliados em ordem aleatória	2.338	57.745	amostra completada antes
Acessíveis na API	2.336	2	erro HTTP definitivo
Usam GitHub Actions	1.346	990	sem workflows
≥ 5 releases na janela	407	939	poucas releases
≥ 50 runs válidos	**300**	107	poucos runs

4.2. Visualização gráfica

A Tabela 4 resume as métricas e a classificação de referência (C1): 80,3% dos repositórios são High ou Medium na categoria geral, com o CFR (a) puxando a nota para cima e a frequência, para baixo. Cada RQ traz, a seguir, a pergunta, o gráfico e os valores-chave.

Tabela 4. Mediana, quartis e nº de repositórios por faixa em C1 (as variantes (b) não entram em C1; CFR (b) calculado com a heurística v3).

					Classificação C1			
Métrica	n	Mediana	Q1	Q3	Elite	High	Medium	Low
Frequência (rel./semana)	300	0,35	0,17	0,70	1	45	157	97
Lead time (a), release (h)	300	187,5	25,7	840,1	72	75	71	82
Lead time (b), commit (h)	300	188,6	34,1	677,1	–	–	–	–
CFR (a), proxy de CI	300	6,1%	2,5%	14,3%	228	45	13	14
CFR (b), proxy de entrega	299	20,0%	0,0%	45,3%	–	–	–	–
Recuperação (h)	272	4,2	0,9	21,5	72	139	38	23
Categoria geral	300	–	–	–	24	126	115	35

RQ01. Qual a frequência de deploys dos repositórios populares que usam CI/CD?

A mediana é 0,35 release/semana ($\approx$ 1,5 por mês; IQR de 0,17 a 0,70), na faixa Medium, como 52,3% dos repositórios (Figura 1). A cauda é longa: só

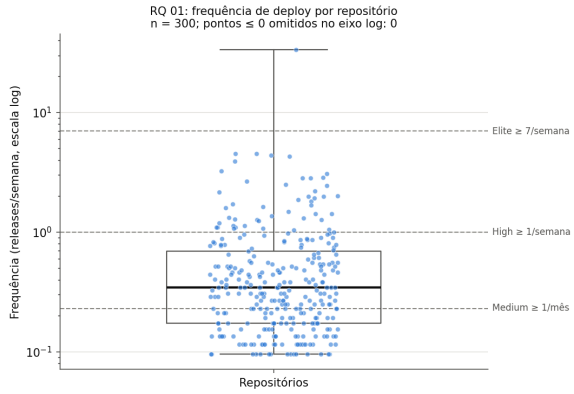


Figura 1. RQ01: frequência de releases (escala log), com mediana, IQR e cortes DORA.

46 (15,3%) publicam ao menos uma por semana, e o único Elite, o monorepo `bluesky-social/atproto`, chega a 33,6.

RQ02. Qual o tempo entre um commit e seu deploy?

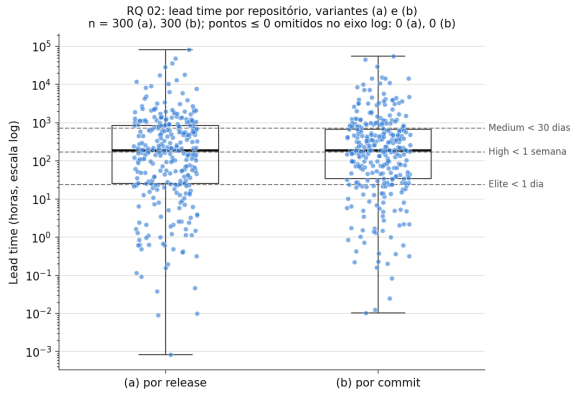


Figura 2. RQ02: lead time por release (a) e por commit (b), em horas (escala log).

As medianas quase coincidem (Figura 2): 187,5 h (≈ 7,8 dias) em (a) e 188,6 h (≈ 7,9 dias) em (b), logo acima do corte de uma semana entre High e Medium. A variante (b) é menos dispersa (IQR de 1,4 a 28,2 dias, contra 1,1 a 35,0) e menor que (a) em 183 repositórios (61,0%), igual em 1 e maior em 116; a mediana da razão b/a é 0,72.

RQ03. Qual a taxa de falha das mudanças entregues?

No proxy de CI (a), a mediana é 6,1% (IQR de 2,5% a 14,3%), e 76,0% dos repositórios são Elite; no de entrega (b), com a heurística v3, é 20,0% (IQR de 0,0% a 45,3%), e 25,4% seriam Low (Figura 3). Das 10.796 releases avaliadas, 46,1% foram seguidas por uma corretiva em até 7 dias; 292 foram censuradas.

RQ04. Qual o tempo de recuperação após uma execução de CI com falha?

A mediana é 4,2 h (IQR de 0,9 a 21,5 h; Figura 4), sobre 9.862 episódios, dos quais só 1,3% foram censurados. Os 28 repositórios sem episódio (em 19, nenhum run falhou) ficam sem valor e são classificados com três métricas.

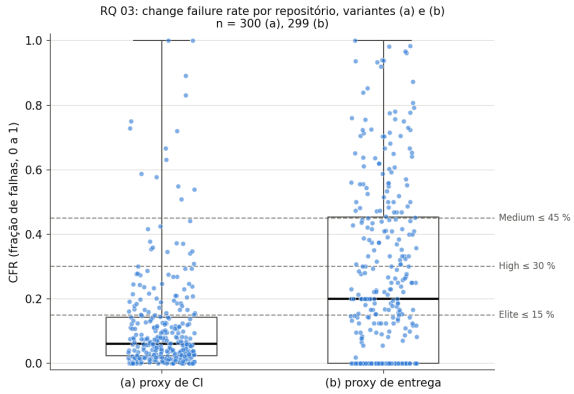


Figura 3. RQ03: CFR nos proxies de CI (a) e de entrega (b), com cortes DORA.

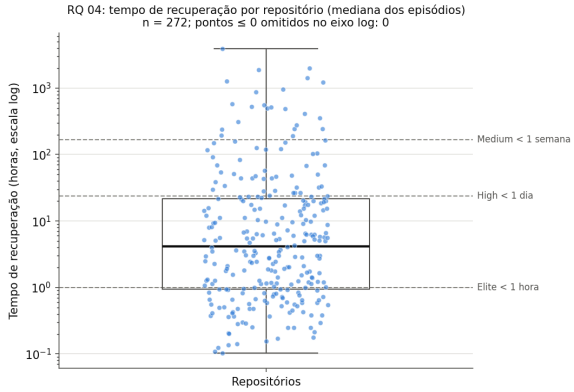


Figura 4. RQ04: tempo de recuperação em horas (escala log), com cortes DORA ($n = 272$).

RQ05. Repositórios com maior frequência de deploy têm maior ou menor taxa de falha?

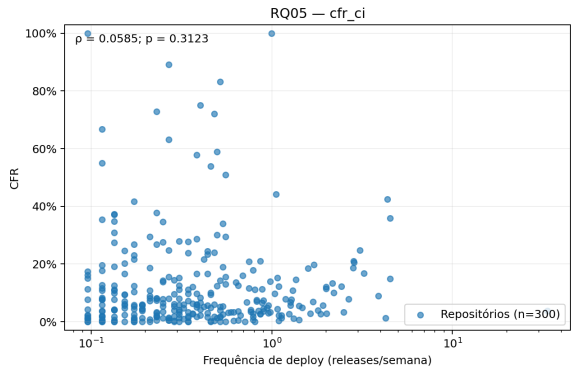


Figura 5. RQ05: frequência (escala log) × CFR (a), proxy de CI.

No CFR de CI, não há associação monotônica detectável ($\rho = 0{,}059$, $p = 0{,}31$, $n = 300$; Figura 5); no de entrega, ela é forte e positiva ($\rho = 0{,}652$, $p < 10^{-36}$, $n = 299$; Figura 6).

RQ06. Quais características estão associadas a melhor desempenho?

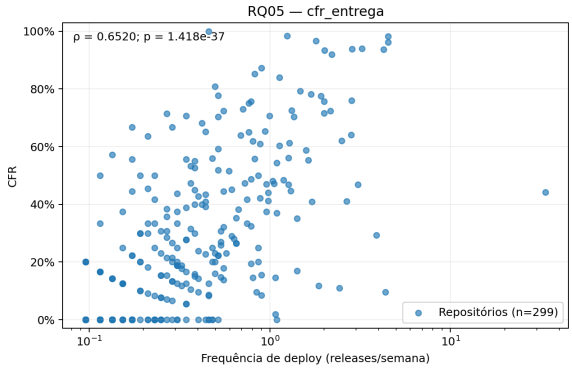


Figura 6. RQ05: frequência (escala log) × CFR (b), proxy de entrega (heurística v3).

Tabela 5. RQ06: testes significativos após a correção de Holm ($\alpha = 0{,}05$).

Fator	Métrica	H	p Holm	ε^2
Estrelas	Lead time (a)	14,5	0,039	0,049
Contribuidores	Lead time (a)	70,5	$7{,}5 \times 10^{-14}$	0,236
Contribuidores	Lead time (b)	43,2	$4{,}2 \times 10^{-8}$	0,145
Contribuidores	CFR (b)	30,1	$2{,}3 \times 10^{-5}$	0,101
Idade	Frequência	44,6	$2{,}2 \times 10^{-8}$	0,149
Idade	Lead time (a)	74,2	$1{,}3 \times 10^{-14}$	0,248
Idade	Lead time (b)	55,9	$9{,}5 \times 10^{-11}$	0,187
Idade	CFR (b)	69,2	$1{,}4 \times 10^{-13}$	0,232

Com quartis de estrelas, contribuidores e idade e o tipo do projeto, 13 dos 24 testes de Kruskal-Wallis tiveram $p < 0{,}05$ e 8 resistiram a Holm (Tabela 5), nenhum por tipo. Do quartil com menos para o com mais contribuidores, o lead time (a) mediano sobe de 23,4 h para 753,9 h; do mais novo para o mais antigo, sobe de 25,9 h para 793,1 h, a frequência cai de 0,65 para 0,21/semana e o CFR (b), de 53,0% para 0,0%.

RQ07. O quanto a classificação DORA depende da definição operacional?

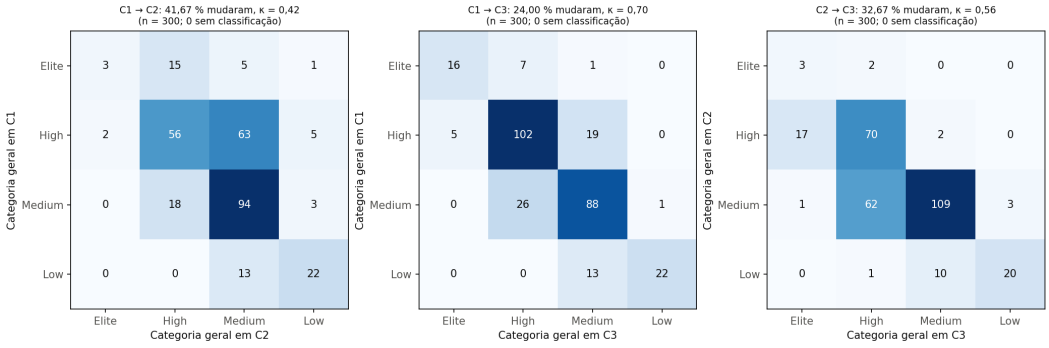


Figura 7. RQ07: transição da categoria geral entre os pares de combinações.

Mudam de categoria geral 41,7% dos repositórios entre C1 e C2 (κ ponderado = 0,42, moderada), 24,0% entre C1 e C3 (0,70, substancial) e 32,7% entre C2 e C3 (0,56,

moderada) (Figura 7); 281 das 295 mudanças são para uma categoria vizinha. Por métrica, trocar o CFR (a) pelo (b) muda a categoria de CFR de 65,6% dos repositórios (159 de 196 para pior); trocar o lead time, de 41,0% (65 melhoram, 58 pioram); e a unidade de deploy, só de 5,7% (pré-releases) e 13,7% (tags), sempre para melhor.

4.3. Discussão

RQ01 – confirmada em parte. Mediana em Medium, assimetria e um único Elite, um monorepo cuja frequência mede publicações de pacotes, não de um produto. Mas a faixa Low não ficou residual (32,3%): o critério de inclusão corta a cauda inferior sem esvaziá-la.

RQ02 – confirmada no repositório, com efeito menor. A variante (b) é menor em 61% dos repositórios, mas as medianas quase coincidem: o commit mais antigo infla (a) sobretudo na cauda (em `phpseclib/phpseclib`, passa de 9 anos). Quando poucas releases grandes concentram os commits, (b) $>$ (a).

RQ03 – confirmada. O CFR (a) mediano é Elite (6,1%), o (b) é mais de três vezes maior (20,0%), e a categoria de CFR muda em 65,6% dos repositórios entre as variantes (RQ07). As variantes medem coisas diferentes: falhas de CI costumam ser corrigidas antes da release, e o CFR (b) se aproxima da falha vista pelo usuário. O CFR (b) é sensível à heurística: a v1 marcava 261 das 300 releases da amostra-ouro como corretivas (precisão de 0,375, contra 103 no consenso), e a troca pela v3 reduziu a mediana de 40,0% para 20,0% e as releases seguidas por corretiva de 7.131 para 4.979.

RQ04 – confirmada. A mediana é 4,2 h, na faixa High, com cauda longa (máximo de 3.958 h) e 1,3% de episódios censurados. O proxy mede o próximo sucesso do workflow (muitas vezes um *re-run* ou um teste corrigido), não a correção de um incidente em produção; a censura (1,3%) quase não afeta a mediana.

RQ05 – confirmada em parte. A correlação é fraca no CI e difere entre as variantes, mas é forte no CFR (b), talvez por efeito mecânico: uma release só falha se outra sair em até 7 dias, o que é mais provável para quem publica mais. Com a v3, ρ caiu de 0,766 (v1) para 0,652, mas continua forte; os dados não indicam causalidade.

RQ06 – confirmada em parte. Contribuidores e idade têm efeitos maiores (ε^2 até 0,25) que estrelas (0,05), mas sobretudo no lead time; mais contribuidores não trazem maior frequência nem recuperação mais rápida (nada resiste a Holm). Repositórios antigos publicam menos, como previsto, mas não têm CFR de CI menor; o CFR (b) menor acompanha a cadência menor. Por tipo ($n = 60$), a falta de diferença reflete baixo poder.

RQ07 – confirmada em grande parte. A média dos pares com C1 (32,8%) fica perto do terço previsto, as mudanças são quase todas adjacentes e dois dos três κ (0,42 e 0,56) caem na faixa prevista; o par C1 $\times$ C3 (0,70) concorda mais. A unidade de deploy pesa pouco, pois a frequência mediana (0,35, 0,38 e 0,47/semana com release, pré-release e tag) fica abaixo de 1/semana; a decomposição por métrica (inovação a) mostra que quem decide é o CFR. Com a v1, as mudanças eram ainda maiores (48,7% em C1 $\times$ C2), ou seja, a sensibilidade depende também da heurística. RQ01 e RQ02 são robustas no agregado; a RQ03, não. **Inovações:** além da (a), o funil (b) estimou a elegibilidade na população (12,8%), e a verificação cruzada (d) reduz o risco de erro na classificação.

Ameaças à validade [Wohlin et al. 2012]. *De construto:* release não é deploy

(embora os avaliadores tenham visto entregas reais nos 60 repositórios rotulados), e falha de CI não é falha em produção; a v3 foi refinada e avaliada na mesma amostra-ouro (F1 possivelmente otimista, meta atingida por pequena margem), e trocar a v1 pela v3 reduziu à metade a mediana do CFR (b); a data da tag é a do commit apontado, e *rebases* e *squash* deslocam `commit.author.date`. *Interna:* idade, tamanho e cadência se confundem, e o CFR (b) depende da frequência; monorepos e linhas de versão paralelas distorcem o pareamento de releases; 24 repositórios podem ter runs incompletos. *Externa:* só projetos populares com Actions e ≥ 5 releases no ano (12,8% dos avaliados), numa única janela. *De conclusão:* 24 testes corrigidos por Holm; tipo do projeto com 60 repositórios desbalanceados; testes sem *post hoc*; p-valor de Spearman aproximado. O estudo não foi replicado por outro grupo; o pipeline é reprodutível por um comando (`config.yaml` e README).

5. Conclusão

Repositórios populares com CI/CD publicam uma release a cada poucas semanas, levam cerca de uma semana do commit à release e recuperam workflows em horas; a maioria é High ou Medium, e idade e contribuidores se associam a lead times maiores. A mensagem principal é metodológica: a classificação DORA depende sobretudo da definição de "falha". As limitações são os proxies, a amostra de projetos populares e a janela única. Com mais tempo, avaliaríamos a heurística fora da amostra-ouro e estenderíamos a decomposição por métrica (inovação a) a várias janelas.

Referências

DORA (2024). DORA's software delivery metrics: the four keys. `https://dora.dev/guides/dora-metrics-four-keys/`.

Forsgren, N., Humble, J., and Kim, G. (2018). *Accelerate: The Science of Lean Software and DevOps*. IT Revolution Press.

Laboratório de Experimentação de Software (2026). Vídeo de referência da disciplina. `https://www.youtube.com/shorts/YwnaeO95AN8`.

Landis, J. R. and Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, 33(1):159–174.

Romano, J., Kromrey, J. D., Coraggio, J., and Skowronek, J. (2006). Appropriate statistics for ordinal level data: Should we really be using t-test and Cohen's d for evaluating group differences on the NSSE and other surveys? In *Annual Meeting of the Florida Association of Institutional Research*.

Wohlin, C., Runeson, P., Höst, M., Ohlsson, M. C., Regnell, B., and Wesslén, A. (2012). *Experimentation in Software Engineering*. Springer.